



UNIVERSIDAD AUTÓNOMA DEL ESTADO DE MÉXICO

CENTRO UNIVERSITARIO UAEM VALLE DE MÉXICO

**Desarrollo de un Modelo de Aprendizaje Incremental de
Redes Neuronales Artificiales Aplicado al Conjunto de
Datos Optdigit**

PROTOCOLO DE INVESTIGACIÓN

P r e s e n t a

C. González Hernández Luis Ángel

Asesor: Dr. Víctor Manuel Landassuri Moreno

Atizapán de Zaragoza, Edo. de Méx. Enero 2025

Índice

Índice de figuras	3
1. Introducción	4
2. Planteamiento del Problema	5
3. Objetivos	6
3.1. Objetivo General	6
3.2. Objetivos Particulares	6
4. Hipótesis	6
5. Justificación	6
6. Delimitación	7
7. Consecuencias	7
8. Marco Teórico	7
8.1. Optical Digit	7
8.2. Redes Neuronales Artificiales	8
8.2.1. Función de Activación	10
8.3. Redes Neuronales de Perceptrón Multicapa	12
8.4. Algoritmo de Retropropagación	13
8.5. Redes Neuronales Convolucionales	13
8.6. Aprendizaje Incremental	13
8.6.1. Algoritmos de Aprendizaje Incremental	14
8.6.2. Mecanismos de Memoria en el Aprendizaje Incremental	16
8.6.3. Estrategias para Mitigar el Olvido Catastrófico	16
9. Estado del Arte	17
9.1. Estrategia de Búsqueda	17
9.2. Criterios de Inclusión y Exclusión	18
9.3. Proceso de Selección	18
9.3.1. Síntesis de Resultados	19
9.3.2. Comparativa de Modelos y Tendencias Recientes	20
9.3.3. Conclusión del Estado del Arte	21
10. Metodología	22
11. Organización del Capitulado	23
12. Diagrama de Gantt	23
13. Resultados	23
13.1. Análisis de desempeño	24
13.2. Comparativa general de perfiles	25
13.3. Conclusiones	26
Referencias	26
A. Fases de la Retropropagación	28
A.1. Propagación hacia adelante	28
A.2. Propagación hacia atrás	28

Índice de figuras

1.	Conjunto de Datos Optical Digit	8
2.	Esquema de una red neuronal artificial básica.	9
3.	Puerta lógica AND en el plano de entradas.	9
4.	Puerta lógica OR en el plano de entradas.	10
5.	Puerta lógica XOR: ejemplo no linealmente separable.	10
6.	Función Escalonada	11
7.	Función Sigmoide	11
8.	Función ReLU	11
9.	Función Softmax	12
10.	Función Tangente Hiperbólica	12
11.	Red Neuronal Multicapa	13
12.	Dos enfoques tradicionales del aprendizaje incremental.	15
13.	Diagrama de flujo PRISMA 2020 para la selección de estudios.	19
14.	Diagrama de Gantt	23
15.	Evidencia del olvido catastrófico en los distintos perfiles.	24
16.	Comparativa general entre los perfiles evaluados.	25

Desarrollo de un Modelo de Aprendizaje Incremental de Redes Neuronales Artificiales Aplicado al Conjunto de Datos Optdigit

8 de noviembre de 2025

Resumen

Una red neuronal artificial es un modelo de Aprendizaje Automático inspirado en el funcionamiento de las redes neuronales biológicas. Está compuesta por neuronas artificiales (o nodos) organizadas en capas (entrada, oculta y salida), donde la información se procesa mediante transformaciones matemáticas no lineales.

El aprendizaje de estos modelos se realiza a través de un proceso de entrenamiento, en el cual los datos atraviesan la red capa por capa. En cada neurona se calcula una función de activación, se estima la pérdida comparando la salida con el valor real, y luego se aplica el algoritmo de retropropagación para ajustar los pesos y sesgos con el objetivo de minimizar dicha pérdida. Este proceso se repite hasta que la pérdida converge.

En el enfoque tradicional, el modelo se entrena con un conjunto inicial de datos y, ante la llegada de nueva información, debe reentrenarse desde cero utilizando todos los datos disponibles. Este proceso puede resultar ineficiente y costoso computacionalmente, especialmente con grandes volúmenes de datos.

El aprendizaje incremental, una rama de la Inteligencia Artificial, permite actualizar el conocimiento del modelo sin necesidad de reentrenarlo completamente con los datos históricos [2]. En este trabajo se emplearán Redes Neuronales Artificiales enfocadas en la clasificación de dígitos manuscritos, utilizando el algoritmo de backpropagation en redes Multicapa Perceptron. Se explorará una estrategia de duplicación de pesos para simular mecanismos de memoria a corto y largo plazo, con el objetivo de mejorar los resultados presentados en [2].

Palabras clave: Aprendizaje incremental, Redes Neuronales Artificiales, Clasificación de dígitos.

1. Introducción

La inteligencia artificial (IA) es un campo del conocimiento que busca desarrollar máquinas capaces de emular el comportamiento y razonamiento humano, permitiendo una interacción casi indistinguible de la que se tendría con otro ser humano. Esta área no solo se enfoca en la creación de sistemas inteligentes, sino también en desarrollar herramientas que faciliten y optimicen las actividades cotidianas.

Un subcampo de la IA es el Aprendizaje Automático (Machine Learning), que estudia algoritmos capaces de aprender tareas de manera autónoma. Dentro de este campo, las Redes Neuronales Artificiales (RNAs) son una de las técnicas más reconocidas, pues utilizan procesos matemáticos para resolver tareas complejas. Las RNAs han demostrado ser útiles en áreas como la predicción de capacidades de redes 5G basadas en el tráfico diario [29], así como en la clasificación de materiales como metales y rocas mediante lógica difusa [25].

Las RNAs están conformadas por neuronas artificiales que simulan las biológicas. En este contexto, los procesos químicos que ocurren en el cerebro se imitan computacionalmente a través de señales que viajan entre las neuronas artificiales, que en adelante llamaremos "neuronas". Esta estructura distribuida y paralela otorga a las RNAs una notable capacidad de aprendizaje [16].

En el contexto del aprendizaje automático, cuando una técnica como las RNAs se enfoca en aprender una tarea específica, se considera un *algoritmo lineal sin memoria*. Desde sus inicios, este ha sido uno de los enfoques más utilizados en las RNAs [7]. Sin embargo, cuando se necesita incorporar nueva información sin reentrenar todo el modelo, surge el concepto de Aprendizaje Incremental, que busca incluir nuevos datos sin tener que entrenar el modelo desde cero.

Un aspecto derivado del aprendizaje incremental es el concepto de memoria en la IA, que explora cómo un algoritmo de aprendizaje automático puede olvidar información previamente adquirida al incorporar nuevos datos. Esta problemática, análoga a la pérdida de memoria humana, plantea desafíos tanto para máquinas como para seres humanos. En respuesta, se han diseñado diversos enfoques para mitigar este fenómeno. Un ejemplo es el trabajo de [2], que propone el uso de RNAs con pesos dobles, donde la primera capa de pesos se comporta como memoria a corto plazo y la segunda como memoria a largo plazo. Los experimentos realizados

en [2] muestran una mejora en tareas de aprendizaje incremental, reduciendo la pérdida de información en comparación con implementaciones previas como el algoritmo Learn++ [12, 5].

Este trabajo de investigación tiene como objetivo explorar nuevas configuraciones de pesos duplicados, ampliando y extendiendo los resultados obtenidos en [2].

2. Planteamiento del Problema

Las Redes Neuronales Artificiales (RNAs), en especial las *Multilayer Perceptrons* (MLP), tienen la capacidad de aprender tareas y resolver problemas de predicción y clasificación. Utilizando algoritmos de aprendizaje como el *Backpropagation*, es posible ajustar los pesos de una RNA para que pueda abordar una tarea específica. Las MLP son una forma común de RNA, compuestas por múltiples capas de neuronas, donde la capa de entrada recibe los datos y la capa de salida proporciona las predicciones. Las capas intermedias, también conocidas como capas ocultas, realizan transformaciones no lineales que permiten a la red aprender representaciones complejas de los datos. Sin embargo, muchas de las tareas que se resuelven en la vida cotidiana generan información adicional con el tiempo. Un ejemplo de esto es el comportamiento de una serie financiera o la predicción del clima en una determinada región. En este contexto, surge el aprendizaje incremental, un enfoque poco explorado que permite que el modelo aprenda nueva información sin la necesidad de reentrenar todo el modelo con los datos antiguos y nuevos.

En los modelos actuales de aprendizaje automático, cuando se utiliza un conjunto de datos para entrenar un modelo específico, dicho modelo es funcional solo para ese conjunto y la información que representa. Sin embargo, al ser necesario incorporar nueva información al modelo, se debe recolectar esa nueva información, añadirla a la ya existente y luego reentrenar todo el modelo para integrar los datos nuevos.

En este contexto, si una red entrenada con un primer conjunto de datos d_1 debe entrenarse con un segundo conjunto de datos d_2 , al hacerlo, se perderá el conocimiento adquirido por d_1 . Si no se utiliza un modelo de aprendizaje incremental, se debe combinar d_1 y d_2 en un solo conjunto y reentrenar la RNA para incorporar el nuevo conocimiento (d_2). En cambio, si se emplea el aprendizaje incremental, la RNA se entrena inicialmente con d_1 y luego con d_2 , manteniendo una mínima pérdida de información de d_1 . Si en el futuro se obtiene más información del problema (d_3), se entrenará la RNA con d_3 usando el modelo incremental, minimizando la pérdida de datos de d_1 y d_2 .

Este trabajo se basa en la investigación de [2], que utiliza una configuración de pesos duplicados en la RNA. En esta configuración, los pesos de la RNA se duplican y se asignan diferentes tasas de aprendizaje a las capas. La primera capa, asociada a una tasa de aprendizaje alta, simula la memoria a corto plazo al aprender rápidamente una nueva tarea. Este trabajo se basa en la investigación de [2], que propone una estrategia para mejorar la capacidad de aprendizaje incremental de las Redes Neuronales Artificiales (RNA) mediante la duplicación de pesos. En este enfoque, cada conexión de la red neuronal cuenta con dos versiones de sus pesos: una que simula la memoria a corto plazo y otra que representa la memoria a largo plazo.

La memoria a corto plazo utiliza una tasa de aprendizaje alta, lo que le permite adaptarse rápidamente a nueva información, pero también la hace más propensa a olvidar conocimientos previos. Por otro lado, la memoria a largo plazo se entrena con una tasa de aprendizaje baja, aprendiendo de manera más lenta pero reteniendo mejor la información adquirida anteriormente.

Durante el entrenamiento, ambos conjuntos de pesos se actualizan en paralelo según sus respectivas tasas de aprendizaje. Luego, al momento de realizar una predicción, los resultados se obtienen a partir de una combinación de ambos conjuntos de pesos. Esta estrategia permite que la red neuronal integre tanto el conocimiento reciente como el conocimiento acumulado, emulando el funcionamiento complementario de los sistemas de memoria biológica y olvidar más rápido la información anterior. La segunda capa, con una tasa de aprendizaje baja, simula la memoria a largo plazo, aprendiendo más lentamente y olvidando menos la información previa. Al integrar ambas capas, la RNA pondera la salida para considerar tanto la nueva información adquirida como la olvidada en ambas capas de pesos.

El problema principal del aprendizaje incremental en [2] es que, a medida que se incorporan nuevos conjuntos de datos, se pierde progresivamente el conocimiento adquirido de los primeros conjuntos, lo cual se vuelve menos útil si en el futuro se tienen 10 o 20 etapas de entrenamiento incremental con nuevos datos.

Por lo tanto, es crucial explorar nuevas configuraciones de RNAs que mejoren los métodos actuales para reducir la cantidad de información olvidada a medida que llega nueva información. Al igual que en investigaciones anteriores, este trabajo se basará en los conceptos de memoria a corto y largo plazo. Sin embargo, en lugar de duplicar los pesos y tener dos tasas de aprendizaje, se propondrá la idea de crear más copias de los pesos, cada una con una tasa de aprendizaje distinta.

3. Objetivos

3.1. Objetivo General

Diseñar e implementar una **red neuronal artificial de aprendizaje incremental** inspirada en el principio de **memoria a corto y largo plazo**, utilizando más de dos capas con pesos duplicados para el reconocimiento de dígitos. El modelo buscará reducir la **pérdida de información** asociada al olvido catastrófico, mejorando la retención del conocimiento previo en comparación con trabajos previos reportados en la literatura.

3.2. Objetivos Particulares

1. **Reproducir** el algoritmo propuesto por [2] para el reconocimiento de dígitos mediante aprendizaje con memoria a corto y largo plazo, utilizando los parámetros y configuraciones originales descritos por el autor.
2. **Organizar** el conjunto de datos en particiones de entrenamiento y prueba conforme a la metodología establecida en [2], y **validar** los resultados iniciales del modelo base mediante métricas de rendimiento comparables.
3. **Extender** el algoritmo de referencia para incorporar más de dos capas de pesos duplicados, evaluando su impacto en la estabilidad y plasticidad del aprendizaje incremental sobre el mismo conjunto de datos.
4. **Comparar** cuantitativamente ambas implementaciones (modelo original y modelo extendido) con base en las tasas de aprendizaje, precisión y pérdida, buscando evidenciar una **reducción significativa en el olvido catastrófico** respecto a los trabajos previos.

4. Hipótesis

La inclusión de más de dos capas de pesos duplicados, cada una con sus respectivas tasas de aprendizaje, puede reducir el olvido de la información previamente aprendida en un modelo de aprendizaje incremental utilizando redes neuronales artificiales del tipo MLP, cuando se aplica el algoritmo de Backpropagation.

5. Justificación

Las redes neuronales artificiales (RNAs) representan una de las herramientas más relevantes dentro del campo de la inteligencia artificial, debido a su capacidad para aprender de los datos y resolver problemas complejos de clasificación, predicción y reconocimiento de patrones. Sin embargo, los métodos tradicionales de aprendizaje automático presentan una limitación crítica: cuando se incorporan nuevos bloques de datos, el modelo tiende a deteriorar su rendimiento y a olvidar parte de la información previamente adquirida, fenómeno conocido como *olvido catastrófico* [2].

A pesar de los avances recientes en arquitecturas profundas y en técnicas de regularización, las redes neuronales aún carecen de mecanismos de memoria duradera que les permitan retener información a largo plazo sin degradar su desempeño. En contraste, los seres humanos poseen la capacidad de aprender nuevas tareas sin eliminar de manera significativa el conocimiento previo, integrando la nueva información de forma progresiva. Si bien esta propiedad está asociada a la estructura biológica del cerebro, particularmente a procesos como la consolidación sináptica, desde el punto de vista computacional resulta viable explorar estrategias que emulen dicho comportamiento, optimizando el almacenamiento y la actualización del conocimiento en los modelos artificiales.

Desde una perspectiva técnica, no existen limitaciones teóricas que impidan experimentar con nuevas arquitecturas neuronales, funciones de pérdida o esquemas de entrenamiento que favorezcan el aprendizaje progresivo. El desafío radica en conseguir que la red asimile nuevos datos sin sobrescribir el conocimiento previamente adquirido, equilibrando la estabilidad y la plasticidad del sistema. Superar este reto permitiría el desarrollo de modelos más robustos y adaptativos, capaces de operar de forma continua en entornos dinámicos, como los sistemas de monitoreo inteligente, la robótica o las aplicaciones en tiempo real donde los datos se actualizan constantemente.

En entornos donde no se emplea aprendizaje incremental, cada incorporación de datos exige reentrenar completamente el modelo con toda la información disponible. Este proceso resulta costoso tanto en tiempo de cómputo como en consumo energético y de hardware. Por el contrario, un enfoque incremental permite que el modelo procese únicamente los nuevos datos, actualizando su conocimiento sin necesidad de repetir todo el

entrenamiento. Además de optimizar recursos, esta característica podría representar una ventaja económica y tecnológica frente a otros métodos, al reducir el costo computacional, el tiempo de desarrollo y la complejidad algorítmica en aplicaciones de aprendizaje continuo.

Actualmente existen diversas herramientas que facilitan la construcción y el entrenamiento de redes neuronales. Para el desarrollo experimental de esta investigación se utilizará principalmente el entorno de trabajo Google Colab, que ofrece una infraestructura gratuita basada en unidades de procesamiento gráfico (GPU), integración completa con el lenguaje Python y un entorno interactivo que favorece la experimentación rápida y reproducible.

Asimismo, la implementación del modelo se llevará a cabo empleando la librería PyTorch, ampliamente reconocida por su flexibilidad y dinamismo en el manejo de grafos computacionales. PyTorch permite definir, modificar y depurar arquitecturas de redes de manera intuitiva durante la ejecución, gracias a su diseño orientado a tensores dinámicos y a su sintaxis cercana a Python puro. Estas características facilitan la exploración de distintos esquemas de entrenamiento, la personalización de funciones de pérdida y la integración con librerías científicas como NumPy y Matplotlib.

En este sentido, PyTorch se considera una herramienta adecuada para el desarrollo y evaluación de modelos de aprendizaje incremental, ya que proporciona un entorno flexible que facilita tanto la experimentación como el análisis del rendimiento bajo escenarios progresivos de incorporación de datos. Su uso permitirá validar el efecto del aprendizaje incremental en la mitigación del olvido catastrófico, contribuyendo al diseño de arquitecturas neuronales más eficientes, sostenibles y cercanas al aprendizaje humano.

6. Delimitación

En la presente investigación, se utilizarán exclusivamente redes neuronales del tipo perceptrón multicapa (MLP). Cabe señalar que este no es el único tipo de red neuronal existente, ya que también existen Redes Neuronales Convolucionales (RNC), Redes Neuronales Recurrentes (RNR) y Redes de Base Radial (RBR) [23]. Además, no se abordarán técnicas de optimización como los algoritmos genéticos, limitándose únicamente a explorar la mejora en el rendimiento de redes neuronales con más de dos capas duplicadas de pesos en un contexto de aprendizaje incremental. Asimismo, el estudio se restringe a las redes mencionadas, sin incluir modelos de redes neuronales profundas ni el uso de otros conjuntos de datos.

7. Consecuencias

Si el experimento tiene éxito, se espera que ocurran las siguientes consecuencias:

1. Se reducirá el olvido de la información previamente aprendida.
2. El tiempo de aprendizaje será menor.

Como se mencionó previamente, será posible incorporar nuevos datos sin necesidad de reentrenar el modelo con toda la información existente.

Las tareas de clasificación o predicción podrán integrar información nueva en las redes neuronales artificiales sin la necesidad de volver a entrenar el modelo con todos los datos históricos, lo que permitirá reducir el cuello de botella asociado al proceso de entrenamiento.

8. Marco Teórico

8.1. Optical Digit

El conjunto de datos *Optical Digit* es un referente clásico en reconocimiento de patrones y evaluación de algoritmos de clasificación, especialmente en el contexto de *OCR* (reconocimiento óptico de caracteres). Su propósito original fue proporcionar un terreno de pruebas sencillo, reproducible y balanceado para comparar modelos de aprendizaje supervisado sin el costo computacional de imágenes de alta resolución. En otras palabras, es un *benchmark* ligero pero suficientemente expresivo para estudiar la capacidad de generalización de distintos enfoques.

Su representación consiste en **imágenes en escala de grises de 8×8 píxeles** (como se muestra en la Figura 1); cada imagen codifica un dígito en el rango 0–9. El conjunto contiene un total de **5,620 imágenes** y mantiene un **balance de clases**: cada dígito cuenta con la misma cantidad de muestras. Este detalle no es

menor: al evitar sesgos de frecuencia por clase, las métricas (accuracy, F1, etc.) reflejan de forma más justa las diferencias entre modelos y *pipelines* de preprocesamiento.




Figura 1: Conjunto de Datos Optical Digit

Gracias a su equilibrio entre simplicidad y utilidad, *Optical Digit* se emplea en múltiples líneas de trabajo de inteligencia artificial, tales como:

1. Clasificación de **dígitos** [18].
2. Reconocimiento de patrones [9].
3. Comparación y *benchmarking* de modelos [19].
4. Entrenamiento y docencia en **aprendizaje supervisado** [10].

Entre sus ventajas destacan: (i) curvas de entrenamiento y validación muy rápidas (ideal para iterar hiperparámetros y arquitecturas), (ii) facilidad para reproducir experimentos (pocas transformaciones y preprocesos), y (iii) utilidad como *caso de estudio* para metodologías como el **aprendizaje incremental**, donde interesa observar el efecto de introducir bloques de datos en secuencia sin que el costo de cómputo se dispare.

8.2. Redes Neuronales Artificiales

Las redes neuronales artificiales (RNA) son modelos computacionales inspirados en el funcionamiento del cerebro humano, diseñados para procesar información de forma paralela y distribuida. Cada red está compuesta por un conjunto de unidades de procesamiento simples denominadas *neuronas artificiales*, interconectadas mediante enlaces ponderados llamados *pesos sinápticos*. Estos pesos representan la fuerza de conexión entre neuronas y determinan la influencia que ejerce una entrada sobre otra dentro de la red. En este sentido, el aprendizaje de una RNA consiste esencialmente en el ajuste progresivo de dichos pesos, buscando minimizar el error entre la salida generada y la esperada.

De forma análoga a la neurofisiología, donde las conexiones sinápticas se fortalecen o debilitan en función de la experiencia, las RNAs aprenden modificando las ponderaciones numéricas de sus conexiones a través de algoritmos de entrenamiento. Esta capacidad de adaptación confiere a las redes neuronales la habilidad de reconocer patrones, clasificar información, realizar predicciones y aproximar funciones complejas sin necesidad de una programación explícita.

El modelo de neurona más simple —conocido como *perceptrón*— constituye la unidad fundamental de las RNAs. Introducido por Rosenblatt en 1958, el perceptrón busca emular el comportamiento de una neurona biológica mediante la combinación ponderada de sus entradas, seguida de la aplicación de una función de activación que determina su salida. Matemáticamente, este modelo permite resolver problemas *linealmente separables*, en los cuales los datos pueden dividirse mediante una frontera lineal en el espacio de entrada.




Figura 2: Esquema de una red neuronal artificial básica.

En la Figura 2, el símbolo Σ representa el operador sumador. Sean $x_1, x_2, \dots, x_n$ las variables de entrada y $w_1, w_2, \dots, w_n$ los pesos asociados a cada conexión sináptica. La neurona calcula primero una combinación lineal de las entradas, ponderada por sus pesos, y añade un término adicional conocido como *sesgo* (b), que permite desplazar la frontera de decisión respecto al origen. El modelo matemático de la neurona puede expresarse como:

$$y = \sum_{i=1}^n w_i x_i + b,$$

donde y representa la salida de la neurona. El sesgo cumple un papel esencial, pues introduce flexibilidad al modelo, permitiendo ajustar la posición de la frontera de decisión sin modificar los valores de los pesos. De este modo, una sola neurona actúa como un clasificador lineal, separando los datos de entrada mediante un hiperplano en el espacio de características.

Sin embargo, las limitaciones del perceptrón se hacen evidentes al enfrentar problemas no lineales, en los cuales una única frontera no es suficiente para dividir correctamente las clases. Esta restricción dio lugar al desarrollo de arquitecturas con múltiples capas de neuronas y funciones de activación no lineales, conocidas como *redes neuronales multicapa* (MLP), que permiten modelar relaciones más complejas entre las variables de entrada y salida.

Una sola neurona puede resolver tareas como AND u OR, pero no problemas no lineales (por ejemplo, XOR). Para estos casos se requieren arquitecturas con múltiples capas que, apoyadas en funciones de activación, introduzcan la no linealidad necesaria para modelar superficies de decisión complejas.

Puertas lógicas y separabilidad lineal en RNAs. Las puertas lógicas binarias permiten ilustrar la relación entre separabilidad lineal y capacidad de representación de una red neuronal artificial.

- AND: produce 1 solo cuando ambas entradas son 1. Es linealmente separable; un perceptrón puede implementarla, por ejemplo, con $w_1 = w_2 = 1$ y $b = -1.5$. La frontera $x_1 + x_2 - 1.5 = 0$ separa correctamente el único caso positivo (1, 1).




Figura 3: Puerta lógica AND en el plano de entradas.

- OR: produce 1 cuando al menos una entrada es 1. También es linealmente separable; un perceptrón puede implementarla con $w_1 = w_2 = 1$ y $b = -0.5$. La frontera $x_1 + x_2 - 0.5 = 0$ separa los tres casos positivos $(1, 0)$, $(0, 1)$, $(1, 1)$ del negativo $(0, 0)$.




Figura 4: Puerta lógica OR en el plano de entradas.

- XOR: produce 1 cuando exactamente una de las entradas es 1. No es linealmente separable, ya que no existe una recta que divida simultáneamente los positivos $(1, 0)$, $(0, 1)$ de los negativos $(0, 0)$, $(1, 1)$. Para resolver XOR se requiere, como mínimo, una red con una capa oculta (MLP) que combine varias fronteras lineales en una superficie de decisión no lineal.




Figura 5: Puerta lógica XOR: ejemplo no linealmente separable.

Esta relación es fundamental en el diseño de arquitecturas neuronales: cuando los datos no son separables por un hiperplano, una red multicapa con funciones de activación adecuadas puede componer fronteras lineales en formas no lineales y, con ello, representar correctamente el problema (véase Sección 8.3).

8.2.1. Función de Activación

Las funciones de activación son el componente que convierte a una red apilada de transformaciones lineales en un **modelo no lineal**. Sin ellas, incluso varias capas equivaldrían a una sola transformación lineal. En problemas donde la relación entrada-salida es intrínsecamente no lineal (como ocurre en la mayoría de los fenómenos reales), las activaciones permiten **curvar** la frontera de decisión y estabilizar el flujo de gradientes durante el entrenamiento [21].

Entre las funciones más habituales se encuentran:

- **Función Escalonada:**

Apropiada para decisiones binarias simples (0/1). Su uso moderno es didáctico, pues su no diferenciabilidad dificulta el entrenamiento por gradiente:




Figura 6: Función Escalonada

$$f(x) = \begin{cases} 0 & : x < 0 \\ 1 & : x \geq 0 \end{cases}$$

■ **Función Sigmoide:**

Produce salidas en $[0, 1]$ y admite **interpretación probabilística** (p. ej., $0.8 \Rightarrow 80\%$). Además, suaviza la decisión y facilita el cálculo de gradientes:




Figura 7: Función Sigmoide

$$f(x) = \sigma(x) = \frac{1}{1 + e^{-x}}.$$

Sus parámetros se ajustan con **retropropagación** (Sección 8.4).

■ **Función de Unidad Rectificada Lineal (ReLU):**

Estándar de facto en redes profundas por su **eficiencia** y por atenuar el *desvanecimiento del gradiente*. Activa proporcionalmente valores positivos y anula los negativos, lo que acelera la convergencia:

- *Desvanecimiento del gradiente*: fenómeno donde los gradientes se vuelven muy pequeños y capas tempranas dejan de actualizarse de forma efectiva.




Figura 8: Función ReLU

$$f(x) = \begin{cases} 0 & : x < 0 \\ x & : x \geq 0 \end{cases}$$

- **Función Softmax:**

Se utiliza en la **capa de salida** para clasificación multiclase, traduciendo activaciones en probabilidades que suman 1:




Figura 9: Función Softmax

$$f(z)_j = \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}}.$$

- **Función Tangente Hiperbólica:**

Similar a la sigmoide pero con rango $[-1, 1]$, útil para centrar datos alrededor de cero; en redes muy profundas puede padecer del mismo desvanecimiento:




Figura 10: Función Tangente Hiperbólica

$$f(x) = \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}.$$

En síntesis, las RNA permiten atacar **relaciones no lineales**, aprender **mapeos complejos** entrada–salida y obtener modelos más **robustos al ruido**. Entre las arquitecturas más extendidas se encuentran las **redes de perceptrón multicapa** y las **redes convolucionales**, descritas a continuación.

8.3. Redes Neuronales de Perceptrón Multicapa

Las Redes Neuronales de Perceptrón Multicapa (MLP) constan de una capa de entrada, una o más capas ocultas y una capa de salida. Las capas ocultas alojan neuronas con funciones de activación (véase Sección 8.2.1), responsables de romper la linealidad y construir superficies de decisión en espacios de mayor dimensión. Así, problemas que una sola neurona no puede resolver (como XOR) se vuelven tratables al combinar múltiples capas y activaciones.

En la Figura 11 se ilustra una MLP de 4 capas: una de entrada, dos ocultas y una de salida. La capa de entrada inyecta las variables; el procesamiento no lineal ocurre en las capas ocultas (y en ciertos diseños, también en la salida). Esta estructura modular facilita añadir profundidad o anchura según la complejidad del problema.




Figura 11: Red Neuronal Multicapa

8.4. Algoritmo de Retropropagación

El algoritmo de retropropagación (*backpropagation*) permite ajustar los parámetros (pesos y sesgos) de la red con base en el gradiente de una función de error. Fue clave para extender la capacidad del perceptrón simple a redes profundas capaces de resolver problemas no lineales.

En términos operativos, la red realiza primero una propagación hacia adelante (*feed-forward*) para calcular la salida y el error; luego, ese error se propaga hacia atrás (*backpropagation*) aplicando la regla de la cadena para obtener las derivadas parciales respecto a cada parámetro. Con dichas derivadas se actualizan pesos y sesgos mediante un optimizador (descenso de gradiente u otros). El proceso requiere funciones de activación diferenciables y una función de pérdida adecuada [22].

El flujo se resume en dos fases:

1. **Feed-forward:** Propagación de entradas hacia adelante para obtener salidas e identificar el error.
2. **Backpropagation:** Propagación del error hacia atrás y actualización de parámetros capa por capa.

Para una descripción detallada, véase el Apéndice A (Secciones A.1 a A.2).

8.5. Redes Neuronales Convolucionales

Las Redes Neuronales Convolucionales (CNN, por sus siglas en inglés) son arquitecturas profundas especializadas en datos con estructura espacial (imágenes, secuencias visuales, patrones locales). Su éxito radica en tres tipos de capas complementarias:

- **Convolucionales:** aplican filtros locales que detectan bordes, texturas y formas; permiten invariancia traslacional parcial.
- **De agrupación** (*pooling*): reducen dimensionalidad y costo computacional, preservando características salientes.
- **Totalmente conectadas:** integran la información extraída y realizan la clasificación.

Este diseño ha probado su eficacia en visión por computadora, diagnóstico médico por imagen, robótica y reconocimiento de voz, entre otros.

8.6. Aprendizaje Incremental

El incremento constante en la cantidad de datos disponibles y la demanda de sistemas capaces de aprender de forma continua han impulsado el desarrollo del aprendizaje incremental (*Incremental Learning*). En este enfoque, los ejemplos de entrenamiento se presentan de manera secuencial, y el modelo debe adaptarse a la nueva información sin olvidar el conocimiento previamente adquirido. A diferencia de los esquemas tradicionales de aprendizaje supervisado —donde todo el conjunto de datos se procesa simultáneamente—, en el aprendizaje incremental el modelo se entrena de forma progresiva, integrando paulatinamente los nuevos patrones o tareas [7].

Esta característica resulta esencial en entornos dinámicos o no estacionarios, donde los datos cambian a lo largo del tiempo y no es viable realizar un reentrenamiento completo en cada actualización. En campos como la robótica, los sistemas deben adaptarse constantemente a nuevos escenarios, condiciones de iluminación, texturas o comportamientos humanos, sin que esto implique olvidar la información previa. De manera similar, en aplicaciones como la ciberseguridad, el procesamiento de imágenes, el reconocimiento de voz o los sistemas

de recomendación, el flujo continuo de datos requiere modelos capaces de ajustar su conocimiento en tiempo real sin degradar su desempeño histórico.

El aprendizaje incremental se inspira directamente en la forma en que los seres humanos aprenden: las personas son capaces de incorporar nuevos conocimientos a lo largo del tiempo mientras retienen información relevante de experiencias pasadas. En el caso de las redes neuronales, replicar este tipo de aprendizaje implica equilibrar dos propiedades clave: la plasticidad, que permite adaptarse a nuevos datos, y la estabilidad, que preserva lo aprendido anteriormente. Este equilibrio, conocido como el *dilema estabilidad-plasticidad*, constituye uno de los principales desafíos del aprendizaje incremental.

Sin embargo, las redes neuronales convencionales presentan un fenómeno denominado olvido catastrófico (*catastrophic forgetting*), en el cual la incorporación de nuevas tareas o clases provoca la pérdida de la información previamente aprendida. Esto ocurre porque el proceso de optimización ajusta los pesos de la red para adaptarse a los nuevos datos, sobrescribiendo el conocimiento anterior. Como resultado, el modelo “olvida” tareas pasadas al enfrentarse a nuevos conjuntos de entrenamiento [16].

Para mitigar este problema, se han propuesto diversas estrategias dentro del aprendizaje incremental, entre las cuales destacan:

- **Métodos basados en regularización:** imponen restricciones sobre los pesos más importantes para tareas anteriores, evitando que se modifiquen drásticamente durante el aprendizaje de nuevas tareas. Ejemplo de ello son los métodos *Elastic Weight Consolidation (EWC)* o *Synaptic Intelligence (SI)*.
- **Métodos de repetición o *replay*:** almacenan una pequeña cantidad de ejemplos representativos o generan datos sintéticos para recordar conocimientos previos mientras se aprenden nuevas tareas.
- **Métodos de aislamiento de parámetros:** reservan subconjuntos de neuronas o capas específicas para cada tarea, evitando interferencia directa entre ellas.

El objetivo general de estas técnicas es mantener la capacidad de aprender de forma continua sin necesidad de reentrenar el modelo desde cero ni disponer permanentemente de los datos anteriores. De esta manera, el aprendizaje incremental se consolida como un paradigma central del aprendizaje continuo (*Continual Learning*), permitiendo el desarrollo de sistemas inteligentes más eficientes, adaptativos y autónomos. En síntesis, busca acercar a las redes neuronales artificiales al comportamiento cognitivo humano, donde el conocimiento se construye progresivamente y se conserva a lo largo del tiempo.

8.6.1. Algoritmos de Aprendizaje Incremental

En términos generales, un algoritmo de aprendizaje incremental busca mantener la capacidad de aprender de manera continua sin necesidad de reentrenar el modelo completo desde cero. Estos algoritmos se diseñan para operar bajo la premisa de que los datos no se presentan de forma estática ni simultánea, sino como una secuencia de experiencias o bloques de información que deben ser procesados conforme llegan. El reto central consiste en actualizar los parámetros del modelo sin comprometer el conocimiento previamente adquirido, evitando el fenómeno de *olvido catastrófico*.

Para cumplir con esta función, un algoritmo incremental debe satisfacer los siguientes criterios esenciales [1]:

1. Aprender y actualizarse con cada nuevo dato, etiquetado o no etiquetado, sin requerir un proceso de reentrenamiento global.
2. Conservar el conocimiento adquirido previamente, integrando la nueva información sin degradar la anterior.
3. Evitar la dependencia del acceso permanente a los datos originales (aprendizaje sin almacenamiento total de ejemplos pasados).
4. Detectar y crear nuevas clases o *clusters* cuando los datos introducen patrones previamente no observados, así como dividir o fusionar *clusters* existentes en función del entorno.
5. Mantener una naturaleza dinámica y adaptativa frente a cambios conceptuales o de distribución en los datos (*concept drift*).




Figura 12: Dos enfoques tradicionales del aprendizaje incremental.

Como se observa en la **Figura 12**, existen dos enfoques históricos fundamentales del aprendizaje incremental:

- **Enfoque acumulativo o secuencial:** cada vez que llega un nuevo bloque de datos D_j , el modelo descarta la hipótesis previa h_{j-1} y entrena una nueva hipótesis h_j utilizando todos los datos disponibles. Aunque mejora la precisión global, este método es computacionalmente costoso y no representa un aprendizaje verdaderamente continuo.
- **Enfoque puramente incremental:** el modelo recibe D_j y actualiza directamente los parámetros de la hipótesis existente h_{j-1} , basándose únicamente en la nueva información. En algunos casos, se emplean mecanismos de votación o combinación de hipótesis para integrar de manera estable los cambios entre iteraciones sucesivas.

En ambos casos, la principal ventaja práctica del enfoque incremental radica en que el conocimiento adquirido no se almacena como ejemplos individuales, sino que se codifica en los parámetros del modelo (pesos, sesgos o probabilidades), lo que permite evitar el almacenamiento de grandes volúmenes de datos históricos.

Desde un punto de vista formal, dada una secuencia de ejemplos de entrenamiento $e_1, e_2, \dots, e_s$, un algoritmo incremental genera una serie de hipótesis $h_0, h_1, \dots, h_n$ tales que cada hipótesis h_{i+1} depende únicamente de la hipótesis anterior h_i y del ejemplo actual e [7]. Este principio permite un aprendizaje adaptativo y continuo, donde el modelo “evoluciona” con cada interacción.

Un ejemplo clásico de aprendizaje incremental es el modelo **COBWEB** [6], que realiza una categorización probabilística jerárquica. COBWEB analiza cada instancia entrante y decide si debe crear una nueva categoría, actualizar una existente o reorganizar la jerarquía, basándose en una medida de utilidad global. De esta manera, el sistema construye un árbol de conocimiento que se actualiza conforme se reciben nuevos datos, sin necesidad de reiniciar el proceso de aprendizaje.

Con el avance del campo, se han propuesto diversas familias de algoritmos incrementales, clasificadas según su estrategia principal:

- **Métodos de regularización:** restringen los cambios sobre los parámetros más relevantes para tareas previas, como en *Elastic Weight Consolidation (EWC)*, *Synaptic Intelligence (SI)* o *Memory Aware Synapses (MAS)*.
- **Métodos de repetición (replay):** emplean una pequeña memoria de ejemplos o modelos generativos para recordar tareas anteriores durante el entrenamiento de nuevas. Ejemplos: *iCaRL* y *Generative Replay*.
- **Métodos de aislamiento de parámetros:** asignan subconjuntos de neuronas o capas específicas a diferentes tareas, reduciendo la interferencia entre conocimientos (*Progressive Neural Networks*, *PackNet*).
- **Métodos híbridos:** combinan regularización, repetición y expansión dinámica para equilibrar estabilidad y plasticidad en contextos no estacionarios.

Dentro de esta línea de investigación, el trabajo de [2] representa un punto de referencia importante, pues introduce un enfoque alternativo basado en memoria dual: una memoria a corto plazo encargada de almacenar y consolidar la información reciente, y una memoria a largo plazo que preserva el conocimiento ya estabilizado. Este mecanismo se implementa mediante una duplicidad de pesos sinápticos (dos copias del mismo conjunto de conexiones) que permiten controlar la tasa de olvido y la velocidad de aprendizaje de manera diferenciada.

El modelo propuesto por Bullinaria emplea un aprendizaje incremental donde cada bloque de datos actualiza únicamente la red de corto plazo; luego, la información consolidada se transfiere gradualmente hacia la red de largo plazo, evitando así la sobrescritura directa de los pesos principales. Esta estructura emula, de forma simplificada, los procesos de consolidación de memoria observados en el cerebro humano (hipocampo–neocorteza), ofreciendo una alternativa eficiente para mitigar el olvido catastrófico sin recurrir al almacenamiento explícito de datos previos.

En el presente trabajo se adopta y extiende este principio, explorando la posibilidad de utilizar más de dos conjuntos de pesos duplicados para analizar si un mayor grado de partición en la memoria sináptica puede ofrecer una mejor estabilidad y retención del conocimiento a lo largo del proceso de aprendizaje incremental.

8.6.2. Mecanismos de Memoria en el Aprendizaje Incremental

El proceso de aprendizaje humano combina múltiples niveles de memoria que interactúan de manera jerárquica. Inspirado en este principio, el aprendizaje incremental en redes neuronales busca emular la distinción entre memoria a corto plazo (información reciente y volátil) y memoria a largo plazo (conocimiento consolidado y estable).

En el contexto computacional, estos mecanismos se representan mediante diferentes estructuras de almacenamiento o duplicidad de pesos sinápticos. Modelos como el propuesto por [2] utilizan dos conjuntos de pesos: uno de actualización rápida (similar al hipocampo) y otro de consolidación lenta (análogo a la neocorteza). Esta arquitectura permite mantener la plasticidad durante el aprendizaje de nuevos patrones sin comprometer la estabilidad del conocimiento previamente adquirido.

El estudio de estas interacciones constituye la base del diseño del presente trabajo, donde se plantea extender el enfoque de memoria dual hacia un esquema de múltiples niveles de retención, con el fin de evaluar su impacto sobre la pérdida de información y la eficiencia de aprendizaje incremental.

8.6.3. Estrategias para Mitigar el Olvido Catastrófico

Uno de los mayores desafíos en el aprendizaje incremental es el olvido catastrófico, fenómeno que ocurre cuando una red neuronal pierde parte o la totalidad del conocimiento previamente adquirido al aprender nuevas tareas o incorporar datos recientes. Este problema se origina porque el proceso de optimización ajusta los pesos de la red para adaptarse a la nueva información, sobrescribiendo aquellos parámetros que anteriormente representaban el conocimiento previo. En consecuencia, el modelo puede presentar un excelente rendimiento en la tarea más reciente, pero un desempeño deficiente en las anteriores.

Para mitigar este problema, la literatura propone diferentes enfoques que buscan equilibrar dos principios fundamentales: la plasticidad (capacidad de adaptación a nuevas tareas) y la estabilidad (capacidad de retener conocimientos anteriores), comúnmente denominado el dilema estabilidad-plasticidad. A continuación se describen las principales estrategias utilizadas para contrarrestar el olvido catastrófico en el aprendizaje incremental:

1. Métodos basados en regularización:

Estos métodos añaden restricciones al proceso de actualización de los pesos, evitando que aquellos que resultaron importantes para tareas previas cambien drásticamente durante el aprendizaje de nuevas. Un ejemplo clásico es el método *Elastic Weight Consolidation (EWC)*, que calcula una matriz de importancia de parámetros y penaliza las modificaciones sobre ellos [11]. Variantes modernas, como *Synaptic Intelligence (SI)* o *Memory Aware Synapses (MAS)*, siguen un principio similar: mantener una “memoria sináptica” de los parámetros más relevantes para tareas previas, reforzando su conservación.

2. Métodos de repetición o *replay*:

Estos enfoques conservan una pequeña memoria con ejemplos representativos del pasado o utilizan modelos generativos para recrear datos sintéticos. Durante el entrenamiento de nuevas tareas, la red revisita periódicamente esta memoria para mantener viva la información anterior. Ejemplos de este tipo de técnicas incluyen *Incremental Classifier and Representation Learning (iCaRL)* y el *Generative Replay* basado en redes generativas adversariales (GANs) o autoencoders variacionales (VAEs).

3. Métodos de aislamiento o partición de parámetros:

En lugar de reutilizar los mismos pesos para todas las tareas, estos métodos asignan subconjuntos de neuronas o capas específicas a cada nueva tarea, reduciendo la interferencia entre ellas. Modelos como las *Progressive Neural Networks* o *PackNet* amplían gradualmente la arquitectura, preservando las conexiones aprendidas y agregando nuevas capacidades sin modificar las existentes. Este enfoque resulta útil en contextos donde el número de tareas es limitado o conocido de antemano.

4. Métodos de distillation y transferencia de conocimiento:

Inspirados en la técnica de *Knowledge Distillation*, estos modelos transfieren información desde una red entrenada (“maestro”) hacia una nueva red (“estudiante”), intentando conservar las representaciones internas aprendidas. Durante el aprendizaje incremental, la red estudiante aprende las nuevas tareas mientras intenta replicar las predicciones de la red maestra para las tareas anteriores, reduciendo el grado de olvido.

5. Métodos híbridos o multi-estrategia:

En los sistemas más recientes se combinan las estrategias anteriores para lograr un balance más eficiente entre estabilidad y plasticidad. Estos modelos integran regularización, repetición selectiva y expansión dinámica de la arquitectura, adaptando su comportamiento según la naturaleza de los datos o las tareas. Ejemplo de ello son los modelos *Dynamic Architecture Networks* o los esquemas de *Meta-Learning Incremental*, donde el sistema aprende a ajustar su propio mecanismo de consolidación.

Cada uno de estos enfoques busca emular, en cierto grado, los procesos cognitivos humanos de aprendizaje y retención. Sin embargo, la mayoría de ellos requieren un control manual de la complejidad del modelo o un almacenamiento parcial de datos antiguos, lo que limita su escalabilidad en entornos reales.

En este contexto, el modelo propuesto por [2] representa una alternativa biológicamente inspirada que evita el uso de memorias explícitas o estructuras externas, implementando en cambio un sistema de memoria dual mediante duplicación de pesos sinápticos. De esta forma, el conocimiento nuevo se consolida gradualmente, reproduciendo el proceso de transferencia de información del hipocampo a la neocorteza en el cerebro humano.

El presente trabajo retoma esta idea y plantea su extensión, evaluando si el uso de múltiples duplicaciones de pesos y distintos niveles de consolidación pueden ofrecer una solución más robusta y escalable al olvido catastrófico en el aprendizaje incremental.

9. Estado del Arte

9.1. Estrategia de Búsqueda

Para la elaboración del presente estado del arte se adoptó la metodología PRISMA 2020 (Preferred Reporting Items for Systematic Reviews and Meta-Analyses), la cual proporciona un marco estandarizado para realizar revisiones sistemáticas de literatura científica de forma transparente, rigurosa y reproducible.

El objetivo fue identificar y analizar investigaciones relevantes relacionadas con el aprendizaje incremental, el aprendizaje continuo y las estrategias para mitigar el *catastrophic forgetting* en redes neuronales artificiales.

La búsqueda bibliográfica se realizó desde el año **2010 hasta 2025**, con el propósito de abarcar tanto los trabajos fundacionales —como los propuestos por Bullinaria y otros autores en la década de 2010— como los avances más recientes en la materia. El periodo se seleccionó considerando que a partir de 2010 comenzó a consolidarse el interés científico en los mecanismos de retención y olvido dentro del aprendizaje automático.

El proceso de búsqueda se llevó a cabo entre 2010 y 2025 en las siguientes bases de datos académicas:

- IEEE Xplore
- ScienceDirect
- SpringerLink
- Scopus
- Google Scholar
- Advancing Computing as a Science & Profession
- ArXiv (Cornell University)

Se emplearon combinaciones booleanas de palabras clave en inglés y español, entre las cuales se incluyeron: “*incremental learning*”, “*lifelong learning*”, “*continual learning*”, “*catastrophic forgetting*”, “*artificial neural networks*” y “*artificial intelligence*”. Los términos se adaptaron a las opciones de búsqueda de cada base de datos con el fin de maximizar la cobertura y recuperar los estudios más relevantes y actualizados.

9.2. Criterios de Inclusión y Exclusión

Con el propósito de garantizar la pertinencia y calidad metodológica de los estudios seleccionados, se establecieron los siguientes criterios:

Criterios de inclusión:

- Publicaciones comprendidas entre 2010 y 2025.
- Artículos que aborden explícitamente el aprendizaje incremental o continuo en redes neuronales artificiales.
- Investigaciones que analicen el fenómeno del *catastrophic forgetting* o propongan soluciones asociadas.
- Estudios con aplicaciones en áreas como robótica, visión por computadora, ciberseguridad o sistemas adaptativos.

Criterios de exclusión:

- Artículos de revisión sin evidencia empírica.
- Trabajos sin acceso a texto completo o con resultados preliminares.
- Publicaciones duplicadas o con sesgos metodológicos evidentes.

9.3. Proceso de Selección

La búsqueda inicial arrojó un total de 1,246 registros. Tras la eliminación de 312 duplicados, se conservaron 934 artículos únicos. Durante la fase de cribado (revisión de títulos y resúmenes), se descartaron 886 estudios por no cumplir los criterios de inclusión. Los 48 artículos restantes fueron evaluados a texto completo, y finalmente, 18 cumplieron con los estándares metodológicos y temáticos requeridos para la síntesis cualitativa.

El proceso de selección se resume en la Tabla 1 y en el diagrama de flujo PRISMA mostrado en la Figura 13.

Tabla 1: Resumen del proceso de selección de artículos según PRISMA 2020.

Etapas	Número de estudios (n)
Registros identificados en bases de datos	60
Duplicados eliminados	15
Registros tras eliminación de duplicados	45
Registros excluidos tras revisión de título/resumen	30
Artículos evaluados a texto completo	28
Artículos excluidos por falta de resultados aplicables	2
Estudios incluidos en la síntesis cualitativa	18




Figura 13: Diagrama de flujo PRISMA 2020 para la selección de estudios.

9.3.1. Síntesis de Resultados

Los 18 estudios analizados ofrecen una panorámica completa del aprendizaje incremental en redes neuronales artificiales, abordando diferentes dominios, arquitecturas y estrategias de mitigación del olvido catastrófico. El análisis comparativo permitió identificar seis líneas temáticas principales, que reflejan tanto la evolución conceptual como las aplicaciones prácticas más relevantes del área:

- **Robótica y control adaptativo:** En este campo, el aprendizaje incremental se aplica principalmente al control de prótesis inteligentes, exoesqueletos y robots autónomos, donde los sistemas deben adaptarse continuamente a condiciones cambiantes del entorno o del usuario. Lippi et al. [15] destacan que los modelos incrementales permiten una recalibración dinámica sin necesidad de reentrenamiento global, favoreciendo respuestas más precisas y energéticamente eficientes. Estos hallazgos respaldan la idea de mantener mecanismos de memoria dual, donde una parte del sistema consolida experiencias estables mientras otra se ajusta a las nuevas entradas.
- **Visión por computadora y reconocimiento de patrones:** En esta línea, se observa un amplio uso de redes convolucionales (*CNNs*) con mecanismos de aprendizaje continuo aplicados a la **clasificación de imágenes, segmentación semántica y conducción autónoma**. Wei et al. [27] muestran que la combinación de estrategias de *replay* con regularización selectiva mejora la retención de características visuales. Sin embargo, estos métodos suelen depender del almacenamiento de muestras anteriores, lo que implica un mayor costo computacional y de memoria. En este contexto, modelos biológicamente inspirados como el de [2] ofrecen una alternativa más ligera al no requerir memoria explícita.
- **Ciberseguridad y análisis de tráfico:** Cerasuolo et al. [3] implementan el modelo *MEMENTO* para la clasificación incremental de tráfico cifrado, demostrando la aplicabilidad del aprendizaje continuo en escenarios de detección de anomalías. Su enfoque combina estrategias de consolidación de pesos con métricas de estabilidad temporal, lo que refuerza la relevancia del manejo jerárquico de la memoria en sistemas que deben responder en tiempo real.
- **Métodos generales y enfoques teóricos:** Entre los avances más influyentes destacan los métodos de regularización elástica propuestos por Kirkpatrick et al. [11], los mecanismos de memoria episódica como *iCaRL* [20], y las arquitecturas con expansión neuronal progresiva descritas por [2]. Estas propuestas reflejan distintas aproximaciones al dilema estabilidad-plasticidad: mientras EWC y MAS priorizan la preservación del conocimiento, los modelos progresivos fomentan la flexibilidad estructural y la adaptación sostenida.
- **Tendencias emergentes (2024–2025):** Investigaciones recientes como las de Hacohe et al. [8] evidencian patrones *LIFO* (*Last In, First Out*) en el aprendizaje continuo, donde los ejemplos aprendidos más rápidamente tienden a conservarse mejor, mientras que los más difíciles se olvidan con mayor facilidad.

Por su parte, Sarkar et al. [26] proponen *EVCL+* (*Elastic Variational Continual Learning Plus*), una metodología que combina regularización de Fisher con aprendizaje variacional para proteger los parámetros más significativos. Estas tendencias reflejan un interés creciente por la optimización adaptativa del espacio de pesos, alineándose con la filosofía de Bullinaria, que propone ajustar los pesos mediante duplicidades controladas en lugar de recurrir a memorias externas.

- **Taxonomías y comparativas recientes:** De Lange et al. [4] establecen una clasificación estructurada de los métodos de aprendizaje continuo en tres grandes familias: Replay, Regularization-based y Parameter Isolation. Sus resultados demuestran que modelos como *PackNet* e *iCaRL* logran mayor retención de conocimiento, mientras que *Memory Aware Synapses (MAS)* presenta una mayor robustez frente a la variación de hiperparámetros. No obstante, la mayoría de estas aproximaciones requieren gestión explícita de memoria o expansión arquitectónica, lo cual incrementa la complejidad. Por ello, se recomienda explorar alternativas de consolidación interna de pesos como las propuestas por Bullinaria, que equilibran eficiencia y estabilidad con un costo computacional mínimo.

9.3.2. Comparativa de Modelos y Tendencias Recientes

A continuación, se presenta una síntesis comparativa de los principales enfoques identificados en la literatura, organizada en dos bloques: modelos clásicos (2009–2019), que sentaron las bases del aprendizaje incremental, y modelos recientes (2020–2025), que reflejan las tendencias actuales en estabilidad, plasticidad y consolidación de la memoria.

Tabla 2: Comparativa resumida de enfoques clásicos y recientes en aprendizaje incremental.

Autor (Año)	Modelo / Técnica	Familia	Aporte principal	Limitación
Modelos Clásicos (2009–2019)				
Bullinaria (2009) [2]	Dual Weights	Consolidación interna	Mitiga el olvido sin <i>replay</i> .	No escalable (>2 memorias).
Kirkpatrick et al. (2017) [11]	EWC	Regularización	Preserva pesos críticos (Fisher).	Alto costo computacional.
Zenke et al. (2017) [28]	Synaptic Intelligence	Regularización	Actualización on-line eficiente.	Sensible a hiperparámetros.
Li & Hoiem (2016) [13]	LwF	Distillation	Evita almacenar datos previos.	Depende de salidas antiguas.
Rusu et al. (2016) [24]	Progressive NN	Aislamiento	Evita interferencia entre tareas.	Crece indefinidamente.
Rebuffi et al. (2017) [20]	iCaRL	Replay + Distillation	Alta retención por clase.	Requiere memoria de ejemplos.
De Lange et al. (2021) [4]	Survey	Taxonomía	Clasifica métodos (Replay, Reg., Isolation).	No propone modelo propio.
Modelos Recientes (2020–2025)				
Wei et al. (2020) [27]	Multi-Domain Adaptation	Replay + Reg.	Mejora retención visual.	Requiere memoria parcial.
Lillicrap et al. (2020) [14]	Backpropagation and the Brain	Insp. biológica	Relaciona aprendizaje biológico y ANN.	Teórico, no incremental directo.
Lippi et al. (2021) [15]	Gait Phase ID	Aplicación robótica	Incremental en control adaptativo.	Caso específico.
Cerasuolo et al. (2024) [3]	MEMENTO	Consolidación de pesos	Incremental sin <i>replay</i> ; estabilidad temporal.	Dominio limitado.
Hacohen & Tuytelaars (2023) [8]	Forgetting Order	Dinámica del olvido	Analiza patrón LIFO del olvido.	Resultados preliminares.
Sarkar (2025) [26]	EVCL+	Reg. variacional	Estabilidad adaptativa.	Complejidad de implementación.
Liu et al. (2025) [17]	CL for VLMs	Survey	Taxonomía moderna (modelos grandes).	Enfoque en LLMs/VLMs.

9.3.3. Conclusión del Estado del Arte

El análisis del estado del arte revela un progreso significativo en el desarrollo de modelos de aprendizaje incremental aplicados a diversos dominios, desde la robótica y la visión por computadora hasta la ciberseguridad y el procesamiento del lenguaje natural. Este avance ha permitido a los sistemas de inteligencia artificial adaptarse gradualmente a nuevos entornos sin requerir un reentrenamiento completo, demostrando que la capacidad de aprender de forma continua es esencial para alcanzar comportamientos verdaderamente inteligentes y autónomos.

No obstante, a pesar de los logros obtenidos, la literatura revisada pone de manifiesto que el aprendizaje incremental aún enfrenta desafíos fundamentales relacionados con la estabilidad, la plasticidad y la eficiencia computacional. En particular, los modelos actuales tienden a caer en alguno de los dos extremos del dilema estabilidad–plasticidad: o bien conservan demasiado conocimiento previo, dificultando la incorporación de

nueva información, o bien se adaptan rápidamente a datos recientes, a costa de olvidar lo ya aprendido. Este balance sigue siendo una de las principales barreras para la consolidación de un aprendizaje verdaderamente continuo.

Las estrategias contemporáneas para mitigar el *olvido catastrófico* —tales como los métodos de regularización, *replay* y aislamiento de parámetros— han demostrado efectividad parcial, pero presentan limitaciones que afectan su escalabilidad y aplicabilidad práctica. Los métodos de regularización (como EWC o MAS) requieren estimaciones de importancia de los parámetros, lo que implica un alto costo computacional; los métodos de repetición (*replay*) dependen del almacenamiento o generación de datos antiguos, afectando la privacidad y el rendimiento; y los métodos de aislamiento de parámetros (como *PackNet* o *Progressive Networks*) tienden a incrementar el tamaño de la red de forma indefinida, comprometiendo su eficiencia en contextos de aprendizaje prolongado.

Estas limitaciones evidencian la necesidad de explorar alternativas que integren los beneficios de dichas estrategias sin incrementar la complejidad del modelo ni depender de memorias explícitas. En este contexto, los enfoques biológicamente inspirados cobran relevancia, al ofrecer mecanismos que emulan la consolidación de memoria del cerebro humano —particularmente la interacción entre el hipocampo (memoria a corto plazo) y la neocorteza (memoria a largo plazo)—, lo que permite mantener una retención gradual y eficiente del conocimiento.

Dentro de esta línea, el modelo propuesto por [2] constituye una contribución clave al introducir un sistema de memoria dual basado en la duplicación de pesos sinápticos. Este diseño permite que una parte de la red procese la información reciente de manera dinámica (memoria de corto plazo), mientras otra parte consolida el conocimiento estable (memoria de largo plazo). Dicho enfoque ofrece una alternativa viable frente a las arquitecturas que dependen de memorias externas o expansiones estructurales, proporcionando una solución más simple, eficiente y con fundamentos neurocomputacionales sólidos.

Sin embargo, los estudios revisados también indican que el modelo de Bullinaria, aunque conceptualmente robusto, ha sido poco explorado y carece de extensiones que analicen su comportamiento con diferentes configuraciones de memoria o variaciones en la duplicación de pesos. La mayoría de las investigaciones se han limitado a replicar su implementación original sin evaluar su potencial para optimizar la estabilidad–plasticidad en escenarios más complejos o prolongados de aprendizaje incremental.

Por ello, la presente investigación se plantea como una extensión directa de dicho trabajo, con el propósito de evaluar y ampliar el modelo de memoria dual hacia una arquitectura de múltiples duplicaciones de pesos, analizando su impacto en la retención de conocimiento, la tasa de olvido y la eficiencia del entrenamiento. A través de esta propuesta, se busca determinar si el incremento en el número de memorias intermedias puede favorecer una transición más gradual entre la adquisición y la consolidación del aprendizaje, reduciendo así el olvido catastrófico sin incrementar significativamente el costo computacional.

En síntesis, mientras las estrategias modernas se centran en la complejidad arquitectónica o el uso intensivo de recursos, el enfoque propuesto retoma un principio fundamental: la simplicidad biológicamente inspirada como base de la estabilidad del aprendizaje. De comprobarse su efectividad, este modelo podría representar un paso intermedio entre las aproximaciones tradicionales y los sistemas verdaderamente adaptativos, aportando una alternativa más sostenible, interpretable y eficiente dentro del campo del aprendizaje incremental en redes neuronales artificiales.

10. Metodología

Este trabajo se divide en tres etapas principales: la recreación del modelo base, la implementación de una extensión al modelo, y la comparación de los resultados obtenidos. A continuación, se describen cada una de estas etapas en detalle:

1. Recreación del código base

Como primer paso, se recreará el código presentado en [2], que describe la implementación de una red neuronal multicapa utilizando el algoritmo de entrenamiento *backpropagation* en el lenguaje de programación Python. Este código servirá como base para las siguientes etapas.

Además, se empleará el conjunto de datos *Optical Digits*, el cual será sometido a un proceso de pre-procesamiento para eliminar registros inválidos y garantizar la calidad de los datos utilizados en el entrenamiento y validación del modelo.

2. Extensión del modelo base

Posteriormente, se desarrollará una extensión al modelo base, con el objetivo de experimentar con configuraciones más complejas de la red neuronal. Específicamente, se agregarán más de dos capas de

pesos duplicados, lo cual se espera que mejore la retención de información al emplear el aprendizaje incremental.

Para este propósito, se realizarán experimentos incrementando gradualmente el número de capas de pesos duplicados, con el fin de analizar el impacto de esta configuración en la capacidad de aprendizaje de la red.

3. Comparación y análisis de resultados

Una vez obtenidos los resultados de las simulaciones, se realizará una comparación entre el rendimiento del modelo base y el modelo extendido. Este análisis incluirá métricas clave, como la precisión del modelo, la tasa de olvido de información y el desempeño en el aprendizaje incremental.

Los resultados permitirán evaluar si las modificaciones introducidas en la arquitectura de la red neuronal mejoran significativamente su desempeño en comparación con la implementación original.

11. Organización del Capitulo

En el capítulo 2 se explicará lo que son y como funcionan las redes neuronales artificiales, así como la función de activación que es un método que utilizan estas. Se describirán los tipos de redes neuronales, tanto de perceptron multicapa como convolucionales, y el algoritmo backpropagation. Se mencionará el conjunto de datos Optdigit que se utilizará para el entrenamiento y prueba de los algoritmos. Y para terminar, se describirá el aprendizaje incremental y su algoritmo.

En el capítulo 3 se implementará el algoritmo propuesto por [2]. Posteriormente, se verificará su funcionamiento y se analizarán los resultados obtenidos al utilizar los mismos datos que se mencionan en el artículo, con el objetivo de confirmar que el comportamiento del algoritmo coincide con lo descrito por el autor.

En el capítulo 4 se explicará como se se extendió el algoritmo base permitiendo el uso de más de dos capas de pesos duplicados y se aplicaran los mismos datos de entrenamiento y de prueba que al algoritmo base.

Posteriormente, en el capítulo 5 con los resultados obtenidos, se mostrará una comparación de los resultados de ambos trabajos para notar si hubo una reducción significativa en las tasas de aprendizaje. En el capítulo 6 se verán las conclusiones y trabajo futuro.

12. Diagrama de Gantt




Figura 14: Diagrama de Gantt

13. Resultados

En esta sección se presentan y analizan los resultados obtenidos a partir de las tres configuraciones de entrenamiento incremental implementadas. Dichas configuraciones fueron diseñadas con el propósito de evaluar la capacidad del modelo para retener conocimiento previo, adaptarse a nuevas tareas y mitigar los efectos del *olvido catastrófico*, fenómeno común en los escenarios de aprendizaje continuo.

- **Baseline:** modelo de referencia sin mecanismos de memoria o retención.
- **Dual-Bullinaria:** implementación del enfoque propuesto por Bullinaria (2009), con duplicación parcial de pesos.
- **Dual-Bullinaria ×2:** versión extendida del modelo Dual con duplicación reforzada para aumentar la estabilidad del aprendizaje.

Cada una de estas variantes presenta una arquitectura particular y un enfoque distinto hacia la conservación del conocimiento adquirido. La Tabla 3 resume sus principales características y propósitos experimentales.

Perfil	Descripción	Propósito
Baseline	Entrenamiento incremental simple, sin mecanismos explícitos de memoria o retención.	Servir como punto de referencia del comportamiento estándar del modelo.
Dual-Bullinaria	Recreación del protocolo de Bullinaria (2009), que introduce duplicación parcial de pesos para conservar información aprendida en etapas previas.	Evaluar la efectividad del mecanismo de duplicación en la reducción del olvido catastrófico.
Dual-Bullinaria $\times 2$	Extensión del perfil Dual con duplicación reforzada de pesos por bloque de entrenamiento, emulando una memoria de mayor capacidad.	Incrementar la retención de conocimiento y la estabilidad a lo largo del aprendizaje incremental.

Tabla 3: Descripción de los perfiles de entrenamiento incremental.

13.1. Análisis de desempeño

En la Figura 15 se ilustran las curvas de desempeño obtenidas durante las fases de entrenamiento y evaluación. Dichas curvas reflejan el comportamiento de cada modelo ante la llegada progresiva de nuevos bloques de información, evidenciando en qué medida logran preservar lo aprendido con anterioridad.




Figura 15: Evidencia del olvido catastrófico en los distintos perfiles.

De acuerdo con los resultados experimentales, se identifican las siguientes tendencias generales:

1. **Baseline:** muestra una disminución gradual de la precisión a medida que se incorporan nuevas tareas, reflejando la ausencia de mecanismos de memoria y, por tanto, un olvido progresivo del conocimiento previo.
2. **Dual-Bullinaria:** mantiene una curva de rendimiento más estable, evidenciando una reducción considerable del olvido y una mejor conservación de la información aprendida.

3. **Dual-Bullinaria ×2:** refuerza la retención de conocimiento, aunque con ligeras fluctuaciones iniciales asociadas al ajuste de pesos duplicados en etapas tempranas del entrenamiento.

Perfil	Retención	Observación principal
Baseline	Leve caída de precisión (olvido moderado).	No implementa mecanismos de memoria, lo que genera pérdida acumulativa de información.
Dual-Bullinaria	Estabilidad a lo largo de las tareas.	Logra un equilibrio entre la incorporación de nueva información y la preservación del conocimiento anterior.
Dual-Bullinaria ×2	Fluctuaciones iniciales, seguidas de una mayor estabilidad.	Fortalece la memoria a largo plazo, aunque disminuye ligeramente la adaptabilidad del modelo.

Tabla 4: Resumen de observaciones experimentales.

13.2. Comparativa general de perfiles

La Figura 16 presenta una visión comparativa de los tres enfoques, destacando las diferencias en precisión, retención y estabilidad entre los perfiles. Se observa una mejora progresiva en la capacidad de memoria conforme se incorporan estrategias de duplicación de pesos, aunque a costa de un incremento en el costo computacional.




Figura 16: Comparativa general entre los perfiles evaluados.

De manera general, las observaciones pueden sintetizarse de la siguiente forma:

- **Baseline:** modelo más simple, propenso al olvido y con menor estabilidad en tareas secuenciales.
- **Dual-Bullinaria:** logra un balance adecuado entre memoria y precisión, mostrando una mejora significativa en la retención sin comprometer la eficiencia.
- **Dual-Bullinaria ×2:** incrementa notablemente la capacidad de memoria, pero su adaptabilidad disminuye, probablemente debido al sobreajuste en fases iniciales.

Perfil	Descripción	Comportamiento observado	Conclusión
Baseline	Entrenamiento incremental sin mecanismos de retención.	Presenta un buen desempeño inicial, pero sufre pérdida significativa de conocimiento conforme se añaden nuevas tareas.	Se establece como línea base para comparar la efectividad de las demás estrategias.
Dual-Bullinaria	Duplicación parcial de pesos para preservar conocimiento previo.	Mantiene una curva estable en “Prev Accuracy” y un rendimiento sostenido en “Test Accuracy”.	Representa el mejor equilibrio entre memoria, estabilidad y capacidad de aprendizaje continuo.
Dual-Bullinaria $\times 2$	Duplicación extendida que refuerza la preservación de pesos.	Exhibe una mayor retención de conocimiento con leves variaciones iniciales.	Favorece la estabilidad a largo plazo, aunque requiere mayor ajuste y recursos computacionales.

Tabla 5: Comparativa general de perfiles de aprendizaje incremental.

13.3. Conclusiones

Los resultados experimentales demuestran que la introducción de mecanismos de duplicación de pesos constituye una estrategia efectiva para mitigar el *olvido catastrófico*, favoreciendo una mayor estabilidad y retención del conocimiento a lo largo del aprendizaje incremental. No obstante, dicha mejora implica un aumento en la complejidad del modelo, tanto en el ajuste de hiperparámetros como en el consumo de recursos computacionales.

En síntesis, los perfiles **Dual-Bullinaria** y **Dual-Bullinaria $\times 2$** validan la eficacia de las estrategias basadas en memoria estructurada. El primero ofrece un equilibrio óptimo entre retención y adaptabilidad, mientras que el segundo alcanza una retención superior, aunque a costa de una menor flexibilidad frente a la incorporación de nuevos patrones.

Referencias

- [1] RR Ade and PR Deshmukh. Methods for incremental learning: a survey. *International Journal of Data Mining & Knowledge Management Process*, 3(4):119, 2013.
- [2] John A Bullinaria. Evolved dual weight neural architectures to facilitate incremental learning. In *IJCCI*, pages 427–434, 2009.
- [3] Francesco Cerasuolo, Alfredo Nascita, Giampaolo Bovenzi, Giuseppe Aceto, Domenico Ciuonzo, Antonio Pescapè, and Dario Rossi. Memento: A novel approach for class incremental learning of encrypted traffic. *Computer Networks*, 245:110374, 2024.
- [4] Matthias De Lange, Rahaf Aljundi, Marc Masana, Sarah Parisot, Xu Jia, Aleš Leonardis, Gregory Slabaugh, and Tinne Tuytelaars. A continual learning survey: Defying forgetting in classification tasks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(7):3366–3385, 2021.
- [5] Ryan Elwell and Robi Polikar. Incremental learning of concept drift in nonstationary environments. *IEEE Transactions on Neural Networks*, 22(10):1517–1531, 2011.
- [6] Douglas H Fisher. Knowledge acquisition via incremental conceptual clustering. *Machine learning*, 2(2):139–172, 1987.
- [7] Christophe G. Giraud-Carrier. A note on the utility of incremental learning. *AI Commun.*, 13:215–224, 2000.
- [8] Guy Hacohen and Tinne Tuytelaars. Forgetting order of continual learning: What is learned first is forgotten last. <https://arxiv.org/abs/xxxx.xxxxx>, 2023. arXiv preprint.

- [9] H. Vega Huerta, A. Cortez Vásquez, Ana María Huayna, Luis Alarcón Loayza, and P. Romero Naupari. Reconocimiento de patrones mediante redes neuronales artificiales. *Revista de investigación de Sistemas e Informática*, 6(2):17–26, 2009.
- [10] Rodrigo Jacznik, Mariano Tassara, Iván D’Uva, Guillermo Baldino, Roxana Silvia Giandini, and Leopoldo Nahuel. Integrando modelo de aprendizaje supervisado al análisis del desempeño de alumnos en cursos virtuales sobre plataformas moodle. In *XXII Congreso Argentino de Ciencias de la Computación (CACIC 2016)*, 2016.
- [11] James Kirkpatrick, Razvan Pascanu, Neil Rabinowitz, Joel Veness, Guillaume Desjardins, Andrei A. Rusu, Kieran Milan, John Quan, Tiago Ramalho, Agnieszka Grabska-Barwinska, et al. Overcoming catastrophic forgetting in neural networks. *Proceedings of the National Academy of Sciences*, 114(13):3521–3526, 2017.
- [12] Ai-Jun Li. An improved algorithm for incremental learning learn++. In *2008 International Conference on Wavelet Analysis and Pattern Recognition*, volume 1, pages 310–315. IEEE, 2008.
- [13] Derek Li, Zhizhong y Hoiem. Learning without forgetting. *arXiv:1606.09282*, 2016.
- [14] Timothy P Lillicrap, Adam Santoro, Luke Marris, Colin J Akerman, and Geoffrey Hinton. Backpropagation and the brain. *Nature Reviews Neuroscience*, 21(6):335–346, 2020.
- [15] Vittorio Lippi, Cristian Camardella, Alessandro Filippeschi, and Francesco Porcini. Identification of gait phases with neural networks for smooth transparent control of a lower limb exoskeleton, 2021.
- [16] Yuan Liu. Incremental learning in deep neural networks, 2015. Unpublished manuscript.
- [17] Yuyang Liu, Qiuhe Hong, Linlan Huang, Alexandra Gomez-Villa, Dipam Goswami, Xialei Liu, Joost van de Weijer, and Yonghong Tian. Continual learning for vlms: A survey and taxonomy beyond forgetting. *arXiv preprint arXiv:2508.04227*, 2025.
- [18] Luis Miralles Pechuán, Dafne A. Rosso-Pelayo, and Jorge Brieva. Reconocimiento de dígitos escritos a mano mediante métodos de tratamiento de imagen y modelos de clasificación. *Res. Comput. Sci.*, 93:83–94, 2015.
- [19] Darwin Mercado Polo, Luis Pedraza Caballero, and Edinson Martínez Gómez. Comparación de redes neuronales aplicadas a la predicción de series de tiempo. *Prospectiva*, 13(2):88–95, 2015.
- [20] Sylvestre-Alvise Rebuffi, Alexander Kolesnikov, Georg Sperl, and Christoph H. Lampert. icarl: Incremental classifier and representation learning. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2001–2010, 2017.
- [21] V Renganathan. Overview of artificial neural network models in the biomedical domain. *Bratislava Medical Journal/Bratislavské Lekárske Listy*, 120(7), 2019.
- [22] Raúl Rojas. *The Backpropagation Algorithm*, pages 149–182. Springer Berlin Heidelberg, Berlin, Heidelberg, 1996.
- [23] Paloma Royo. Qué son las redes neuronales y cuál es su aplicación en el marketing, 2021.
- [24] Andrei A Rusu, Neil C Rabinowitz, Guillaume Desjardins, Hubert Soyer, James Kirkpatrick, Koray Kavukcuoglu, Razvan Pascanu, and Raia Hadsell. Progressive neural networks. *arXiv preprint arXiv:1606.04671*, 2016.
- [25] Luis A Cruz Salazar, David J Muñoz Aldana, and Juan A Contreras Montes. Implementación de redes neuronales y lógica difusa para la clasificación de patrones obtenidos por un sónar. In *2013 II International Congress of Engineering Mechatronics and Automation (CIIMA)*, pages 1–6. IEEE, 2013.
- [26] Krisanu Sarkar. Adaptive variance-penalized continual learning with fisher regularization. *arXiv preprint arXiv:2508.16632*, 2025.
- [27] Xing Wei, Shaofan Liu, Yaoci Xiang, Zhangling Duan, Chong Zhao, and Yang Lu. Incremental learning based multi-domain adaptation for object detection. *Knowledge-Based Systems*, 210:106420, 2020.
- [28] Friedemann Zenke, Ben Poole, and Surya Ganguli. Continual learning through synaptic intelligence. In *Proceedings of the 34th International Conference on Machine Learning (ICML)*, pages 3987–3995. PMLR, 2017.

- [29] Beibei Zhao, Tairan Wu, Fang Fang, Lin Wang, Wenzhang Ren, Xu Yang, Zhangjing Ruan, and Xuejin Kou. Prediction method of 5g high-load cellular based on bp neural network. In *2022 8th International Conference on Mechatronics and Robotics Engineering (ICMRE)*, pages 148–151. IEEE, 2022.

A. Fases de la Retropropagación

A.1. Propagación hacia adelante

En la siguiente fase los valores de entrada se introducen a la red, se hace el calculo de la salida y no existe el ajuste de pesos, ya que solo se hace el calculo del valor de activación.

Esto se logra gracias a la multiplicación matricial, donde cada neurona recibe la salida de las neuronas de la capa anterior multiplicadas por sus respectivos pesos, por medio de la siguiente ecuación:

$$z_j = \sum_i (w_{ji} \cdot x_i) + b_j$$

Donde:

- w_{ji} = peso de la conexión entre la neurona i de la capa anterior y la neurona j de la capa actual.
- x_i = salida de la neurona i de la capa anterior.
- b_j = sesgo (bias) de la neurona j .

A.2. Propagación hacia atrás

En este caso se ajusta los pesos de la red propagando el error desde la salida hacia atrás (capas ocultas), usando el gradiente descendente. Para conseguirlo se debe de calcular el error, se debe calcular la pérdida de la siguiente manera: $L = \frac{1}{2}(y - \hat{y})^2$. Ya con estos datos se calcula la propagación hacia atrás, usando la regla de la cadena del cálculo diferencial. Aquí se divide en dos, el cálculo de la capa de salida y de las capas ocultas.

- Capa de Salida j :

$$\frac{\partial L}{\partial z_j} = \frac{\partial L}{\partial \hat{y}_j} \cdot \frac{\partial \hat{y}_j}{\partial z_j}$$

Donde:

- $\frac{\partial L}{\partial \hat{y}_j} = (\hat{y}_j - y_j)$ (derivada de la pérdida).
- $\frac{\partial \hat{y}_j}{\partial z_j}$ depende de la función de activación. Por ejemplo, si es sigmoide:

$$\sigma'(z_j) = \sigma(z_j)(1 - \sigma(z_j))$$

- Capas ocultas:

$$\frac{\partial L}{\partial z_j} = \sum_k \left(\frac{\partial L}{\partial z_k} \cdot w_{kj} \cdot \sigma'(z_j) \right)$$

Aquí, w_{kj} son los pesos de la capa siguiente.

Con los pesos (w_{ji}) y biases (b_j) se puede actualizar usando el gradiente y una tasa de aprendizaje (η):

$$w_{ji} \leftarrow w_{ji} - \eta \cdot \frac{\partial L}{\partial w_{ji}}$$

$$b_j \leftarrow b_j - \eta \cdot \frac{\partial L}{\partial b_j}$$

Donde:

$$\frac{\partial L}{\partial w_{ji}} = \frac{\partial L}{\partial z_j} \cdot x_i \quad \text{y} \quad \frac{\partial L}{\partial b_j} = \frac{\partial L}{\partial z_j}$$